

НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ
«Київський політехнічний інститут імені Ігоря Сікорського»
Факультет інформатики та обчислювальної техніки
Кафедра технічної кібернетики

Звіти до комп'ютерних практикумів з кредитного модуля
“Вступ до Data Science”

Виконав

Студент групи IT-02

Макаров І.С.

Перевірів:

Професор кафедри ОТ ФІОТ

Писарчук О.О.

Комп'ютерний практикум No 1.

ДОСЛІДЖЕННЯ СТАТИСТИЧНИХ ХАРАКТЕРИСТИК ЕКСПЕРИМЕНТАЛЬНИХ ДАНИХ

Мета:

Виявити дослідити та узагальнити особливості застосування методів статистичного аналізу для задач визначення статистичних характеристик вхідного потоку експериментальних даних з використанням спеціалізованих пакетів мови програмування Python.

Варіант:

Я 10й у списку, той ось мій варіант, другий рівень складності

Закон зміни похибки – рівномірний, нормальний; Закон зміни досліджуваного процесу – кубічний, лінійний.
--

ВИКОНАННЯ

Структура проекту це один файл **laba1.ipynb**.

```
kinfi4@me ~/p/k/D/laba1 (master)> tree
.
├── L_2_statistics.py
├── laba1.ipynb
└── laba1-Makarov.ipynb.gz
0 directories, 3 files
```

Діаграма:



Перш за все вкажемо потрібні нам імпорти, та напишемо функцію, що буде виводити числові характеристики переданої вибірки. Також вкажемо default розмір наших вибірок.

```
In 1 1 import numpy as np
      2 import matplotlib.pyplot as plt

In 2 1 def calculate_metrics(sample: np.ndarray) -> None:
      2     print(f'Mathematical expectation: {np.median(sample)}')
      3     print(f'Dispersion: {np.var(sample).round(3)}')
      4     print(f'Sigma: {np.std(sample).round(3)}')
      5     print('=' * 50)
```

Constants


```
In 15 1 default_distribution_size = 10000
```

ЧАСТИНА 1

Спочатку розберемось з рівномірним розподілом, де не випадкова складова це кубічний процес.

```
In 4 1 small_distribution_size = 100
      2 uniform_distribution = np.random.uniform(-50, 50, small_distribution_size).astype(int)
      3
      4 plt.hist(uniform_distribution, bins=20, color='r')
      5 plt.show()
      6 calculate_metrics(uniform_distribution)
      7
      8 uniform_distribution = np.random.uniform(-50, 50, default_distribution_size).astype(int)
      9
     10 plt.hist(uniform_distribution, bins=20, color='r')
     11 plt.show()
     12 calculate_metrics(uniform_distribution)
```

В даному коді, я створив дві вибірки, першу зі 100 елементів, друга з default значенням розміру вибірки (10 000) елементів. Зробив я це, аби показати ЗВЧ на практиці.




Як видно мат
характеристики у двох
вбірок майже однакові,
однак в першій вгадати
рівномірний розподіл навряд
можна, все через малу кількість
елементів вибірки.

Додамо не випадкову складову

Correcting the distribution

```
In 26 1 coefficient = 0.0000000019
      2 correction_array = np.arange(uniform_distribution.shape[0])
      3 correction_array = (correction_array ** 3) * coefficient
      4
      5 corrected_distribution = uniform_distribution + correction_array
      6
      7 plt.plot(corrected_distribution)
      8 plt.plot(correction_array, color='red')
      9 plt.show()
     10
     11 calculate_metrics(corrected_distribution)
```




Mathematical expectation: 46.54511374946
Dispersion: 3711.168
Sigma: 60.919

Тепер подивимось на порівняння нашого розподілу, і окремо глянемо як виглядає наша адитивна модель.

Let's compare


```
In 6 1 plt.hist(uniform_distribution, bins=20, alpha=0.5)
      2 plt.hist(corrected_distribution, bins=20, alpha=0.5)
      3
      4 plt.show()
```



Як видно закон розпався, що свідчить про нелінійний невинпадковий тренд
Тепер, оскільки ми знаємо як виглядає наш `correction_array`, то можемо його відняти

Take in consideration the dinamic of change

```
In 7 1 corrected_back_distribution = corrected_distribution - correction_array
      2
      3 plt.hist(uniform_distribution, bins=20, alpha=0.5)
      4 plt.hist(corrected_distribution, bins=20, alpha=0.5)
      5 plt.hist(corrected_back_distribution, bins=20, alpha=0.5)
      6
      7 plt.show()
```




Частина 2

Тепер час сісти за нормальний закон, початок схожий.

Normal Distribution

```
In 12 1 mean, sigma = 0, 10
      2 normal_distribution = np.random.normal(mean, sigma, size=default_distribution_size).astype(int)
      3
      4 plt.hist(normal_distribution, bins=20, color='r')
      5 plt.show()
      6 calculate_metrics(normal_distribution)
```




```
Mathematical expectation: 0.0
Dispersion: 91.928
Sigma: 9.588
=====
```

Побудуємо не випадкову складову.

Correcting the distribution

```
In 13 1 coefficient = 0.004
      2 correction_norm_array = np.arange(normal_distribution.shape[0])
      3 correction_norm_array = correction_norm_array * coefficient
      4
      5 corrected_norm_distribution = normal_distribution + correction_norm_array
      6
      7 plt.plot(corrected_norm_distribution)
      8 plt.plot(correction_norm_array)
      9 plt.show()
     10
     11 calculate_metrics(corrected_norm_distribution)
```




```
Mathematical expectation: 20.092
Dispersion: 226.245
Sigma: 15.041
=====
```

Але тут в нас лінійний закон не випадкової величини.
Ну що, візуалізуємо, що в нас вийшло

Let's compare

```
In 14 1 plt.hist(normal_distribution, bins=20, alpha=0.5)
      2 plt.hist(corrected_norm_distribution, bins=20, alpha=0.5)
      3
      4 plt.show()
```




Як видно, закон не розпався, бо тренд лінійний.

Ну і нарешті, оскільки ми знаємо `correction_norm_array`, можемо відняти його


Take in consideration the dinamic of change

```
In 11 1 corrected_back_norm_distribution = corrected_norm_distribution - correction_norm_array
      2
      3 plt.hist(normal_distribution, bins=20, alpha=0.5)
      4 plt.hist(corrected_norm_distribution, bins=20, alpha=0.5)
      5 plt.hist(corrected_back_norm_distribution, bins=20, alpha=0.5)
      6
      7 plt.show()
```



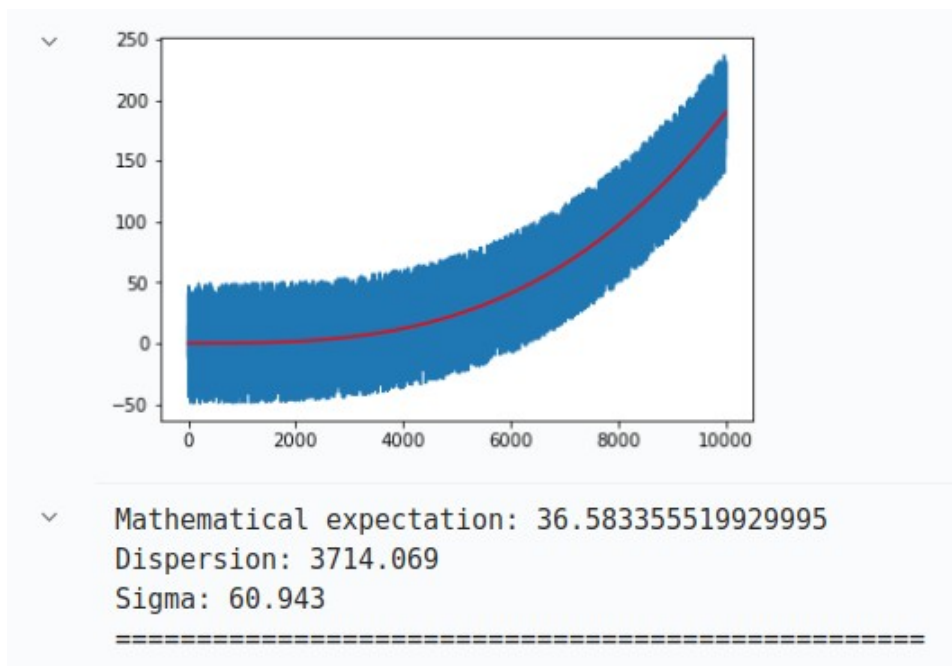
ДОВЕДЕННЯ ПРАЦЕЗДАТНОСТІ

Думаю з графіків доволі очевидно, що скрипт працює. В першій частині ми генерували рівномірно розподілену вибірку, від -50 до 50.



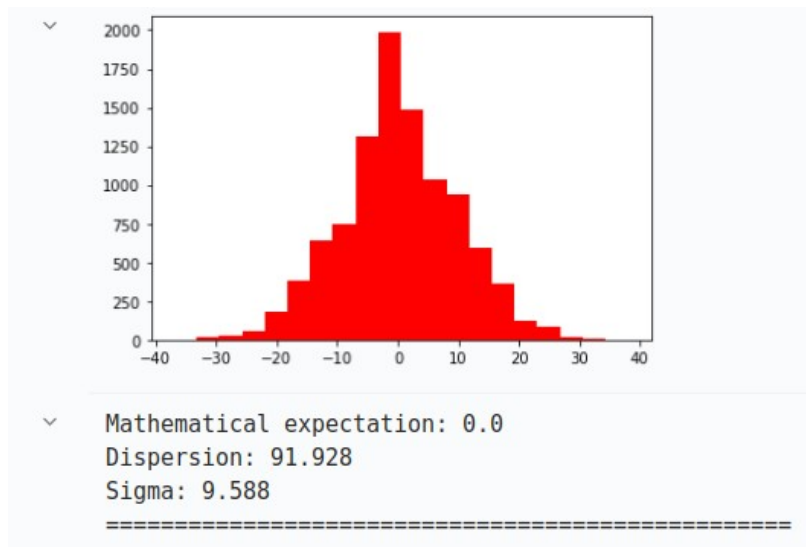
Доволі очевидно, що візуалзація, та мат. характеристики описують такий розподіл.

Так само адитивна модель, з кубічною не випадковою складовою очевидно справедлива




Щодо нормального розподілення.


Я вказував $M = 0$ та $\sigma = 10$, що більш менш в нас і вийшло.



Але тут вже тренд лінійний



Що до речі, як видно не руйнує наш закон



ВИСНОВОК

В ході роботи я створив скрипт на мові програмування Python. Скрипт генерує дві випадкові величини, рівномірного та норм розподілу. А також дві не випадкові величини, лінійну та кубічну. Та створює адитивні моделі відповідних вип та невип величин. А також робить візуалізацію.